Projet Knowledge Extraction - Partie A

Aya BENKABBOUR, Boutayna El MOUJAOUID, Franz DERVIS, Jacques GASTEBOIS
https://github.com/635jack/Projet_Semantique_AB_BEM_FD_JG

Université Paris Cité
Pr. Salima Benbernou

INTRODUCTION ET CORPUS

Ce projet s'inscrit dans une démarche d'extraction de connaissances structurées (Named Entity Recognition - NER) à partir de données textuelles non structurées. Le corpus utilisé est le **WikiNER**, un dataset multilingue "silver-standard" construit automatiquement à partir d'articles Wikipédia. Il annoté pour identifier les Personnes, Lieux et Organisations. Ce rapport se concentre sur notre sous-ensemble de **700 phrases** (principalement biographiques et encyclopédiques) et sur la chaîne de traitements (preprocessing) mise en oeuvre pour préparer ces données à l'étape d'apprentissage. **Volumétrie** : Le corpus contient 700 phrases annotées, avec une longueur moyenne de 24 mots. L'étape de preprocessing est cruciale pour réduire le bruit (cf. Fig. 3).

MÉTHODOLOGIE DE PREPROCESSING

Contrairement à une simple approche "Bag of Words", j'ai développé un pipeline en Python (via Jupyter Notebook) visant à préserver la structure séquentielle du texte, dimension essentielle pour la tâche de NER. 1. **Nettoyage** : Conversion en minuscules, suppression des métadonnées et caractères spéciaux. Cette étape normalise les entrées tout en réduisant drastiquement le bruit (outliers de longueur). 2. **Lemmatization** : Réalisée avec **spaCy**, elle transforme chaque mot en sa forme canonique. Cela permet de réduire la taille du vocabulaire de **14.2%** (passant de 4990 à 4280 termes), densifiant ainsi l'information sémantique pour les modèles futurs. 3. **Enrichissement** : Le dataset final (`data_preprocessed.csv`) contient à la fois le texte brut, nettoyé et lemmatisé.

ANALYSE (STATS & POS & TF-IDF)

Une analyse statistique approfondie a été menée pour caractériser le corpus : **Lexicale** : Les nuages de mots (consultables sur la démo) révèlent les thématiques dominantes. Les mots les plus fréquents (cf. Fig. 2) confirment cette tendance. **POS (Part-of-Speech)** : L'analyse grammaticale montre une très forte prédominance des Noms et Noms Propres (30.5%). Cette distribution (cf. Fig. 1) est directement corrélée à la nature biographique et factuelle des articles Wikipédia, riches en mention d'entités nommées. **TF-IDF** : Une matrice de 700x2493 a été générée avec une densité de 0.77%. Les hyperparamètres ont été finement ajustés :

- `max_df=0.8` : Pour filtrer les "stop-words" spécifiques au corpus (présents dans +80% des documents).
- `min_df=2` : Pour éliminer le bruit (fautes de frappe, hapax) et réduire la dimensionnalité.
- `ngram_range=(1,2)` : Inclusions des bigrammes pour capturer des concepts composés (ex : "machine learning"), essentiels pour le contexte.

ANALYSE CRITIQUE & IMPACT

1. Lemmatization (spaCy) : Préserve le sens sémantique (extraction de relations) malgré le coût de calcul, préféré au Stemming. **2. Lowercasing** : Réduit le vocabulaire mais perd la capitalisation (indice NER). *Mitigation* : Conservation du texte original dans une colonne dédiée. Une règle partielle (début de phrase) serait trop fragile (Allemand, listes). **3. Structure Séquentielle** : Pas de vectorisation pour l'export final. Indispensable pour le NER, au prix de fichiers plus volumineux.

Impact Suite Projet Partie II (NER) : Nécessitera le texte original (capitalisation) + lemmatisé (embeddings sémantiques). **Partie C (Relations)** : Bénéficie de la lemmatization (normalisation des verbes, simplification des dépendances).

DÉMO & CONCLUSION

Démo : https://jacquesgastebois-projetsemantique.streamlit.app/ (Visualisation, Stats, Pipeline interactif). Conclusion : Le preprocessing (compromis bruit/info) offre un socle robuste pour le NER et l'extraction de relations.

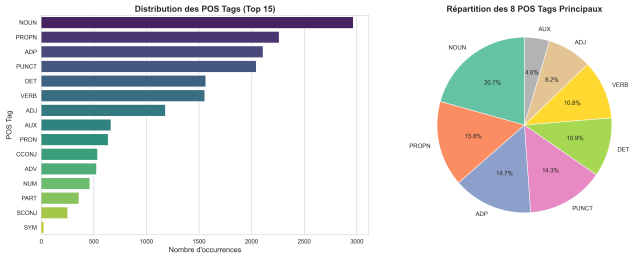

FIGURE 1 – Distribution POS (Noms dominants)

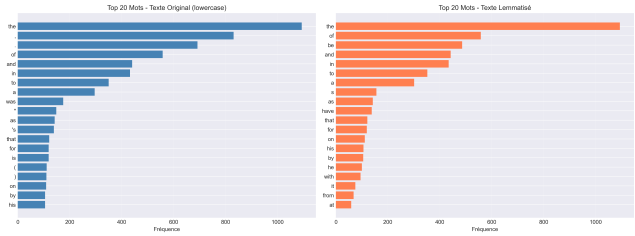

FIGURE 2 – Top Mots fréquents

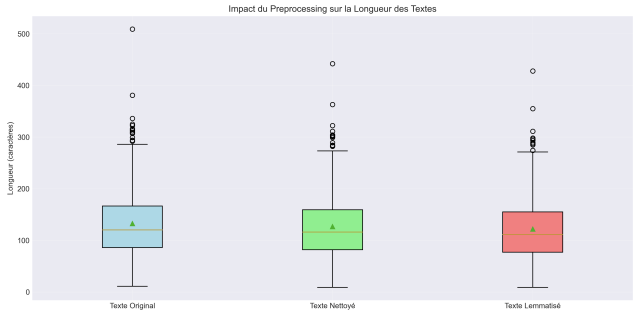

FIGURE 3 – Impact du Preprocessing